

UFC - Mineração de Dados

Laboratório #03

Desafio de Clusterização: Análise de Comportamento de Clientes de Cartão de Crédito

Contexto do Desafio

Você foi contratado como Cientista de Dados por uma instituição financeira que deseja entender melhor o comportamento de seus clientes de cartão de crédito. A empresa quer segmentar seus clientes para:

1. **Criar campanhas de marketing personalizadas**
2. **Identificar clientes com risco de cancelamento**
3. **Detectar padrões de uso atípicos que possam indicar fraude**
4. **Oferecer produtos financeiros adequados a cada perfil**

Sua missão é analisar os dados, escolher o(s) algoritmo(s) de clusterização mais adequado(s) e justificar sua escolha.

Dataset: Credit Card Customer Data

Fonte: UCI Machine Learning Repository / Kaggle **Registros:** ~9000 clientes **Features:** 18 variáveis comportamentais

Descrição das Variáveis:

Variável	Descrição
BALANCE	Saldo da conta
BALANCE_FREQUENCY	Frequência de atualização do saldo (0-1)
PURCHASES	Total de compras realizadas

Variável	Descrição
ONEOFF_PURCHASES	Compras à vista
INSTALLMENTS_PURCHASES	Compras parceladas
CASH_ADVANCE	Valor de saques em dinheiro
PURCHASES_FREQUENCY	Frequência de compras (0-1)
ONEOFF_PURCHASES_FREQUENCY	Frequência de compras à vista
PURCHASES_INSTALLMENTS_FREQUENCY	Frequência de compras parceladas
CASH_ADVANCE_FREQUENCY	Frequência de saques
CASH_ADVANCE_TRX	Número de transações de saque
PURCHASES_TRX	Número de transações de compra
CREDIT_LIMIT	Limite do cartão
PAYMENTS	Total de pagamentos realizados
MINIMUM_PAYMENTS	Valor mínimo de pagamentos
PRC_FULL_PAYMENT	Percentual de pagamentos integrais
TENURE	Tempo como cliente (em meses)

Objetivos do Desafio

Parte 1: Análise Exploratória (20 pontos)

1. Carregue e explore o dataset
2. Identifique valores ausentes e trate-os adequadamente
3. Analise a distribuição das variáveis
4. Identifique outliers
5. Normalize/padronize os dados quando necessário
6. Crie visualizações que ajudem a entender os dados

Parte 2: Escolha do Algoritmo (40 pontos)

Você deve testar TODOS os três algoritmos:

K-Means

- Implemente o método do cotovelo
- Implemente o Silhouette Score
- Teste com diferentes valores de k (3-10)
- Analise os resultados

DBSCAN

- Experimente diferentes valores de `eps` (use gráficos k-distance)
- Teste diferentes valores de `min_samples`
- Identifique quantos outliers foram detectados
- Avalie se os clusters fazem sentido

Clusterização Hierárquica

- Crie e analise o dendrograma
- Teste diferentes métodos de linkage (ward, complete, average)
- Determine o número ideal de clusters
- Compare com os outros métodos

Parte 3: Justificativa e Recomendação (30 pontos)

Responda as seguintes questões:

1. Qual algoritmo você recomenda e por quê?

- Considere: qualidade dos clusters, interpretabilidade, escalabilidade

2. Os clusters encontrados fazem sentido do ponto de vista de negócio?

- Descreva cada cluster encontrado
- Dê nomes significativos aos clusters (ex: "Compradores Frequentes", "Clientes Inativos")

3. Quais insights você extraiu dos clusters?

- Que ações a empresa deveria tomar para cada segmento?

4. Houve outliers significativos?

- O que eles podem representar? (fraudes? clientes VIP? erros nos dados?)

5. Qual seria sua recomendação final para a equipe de negócios?

Parte 4: Bônus (10 pontos extras)

- Implemente pelo menos uma métrica de validação adicional (Davies-Bouldin, Calinski-Harabasz)
 - Crie visualizações em 2D usando PCA ou t-SNE
 - Compare seu melhor resultado com um ensemble/combinação de algoritmos
 - Proponha features adicionais que poderiam melhorar a análise
-



Entregáveis

1. **Notebook Jupyter** (.ipynb) com:
 - Código bem comentado
 - Análises e visualizações
 - Markdown explicando cada etapa
 2. **Relatório Executivo** (PDF ou Markdown) com:
 - Resumo executivo (1 página)
 - Metodologia utilizada
 - Resultados e visualizações principais
 - Recomendações de negócio
 3. **Apresentação** (opcional - 5-10 slides) resumindo:
 - O problema
 - Sua abordagem
 - Resultados principais
 - Recomendações
-



Dicas e Orientações

Dicas de Análise:

1. **Tratamento de Missing Values:**
 - Não ignore valores ausentes!
 - Considere imputação pela mediana ou média

- Documente suas decisões

2. Normalização:

- SEMPRE normalize os dados antes de aplicar algoritmos de distância
- Use StandardScaler ou MinMaxScaler

3. Redução de Dimensionalidade (BONUS):

- Como este tópico ainda vai ser apresentado, ficará como bonus
- Com 17 features, pode ser útil aplicar PCA
- Mantenha 90-95% da variância explicada

4. Interpretação:

- Não se limite a números - entenda o significado dos clusters
- Pense como um analista de negócios

Perguntas Guia para Escolha do Algoritmo:

Critério	K-Means	DBSCAN	Hierárquica
Você sabe quantos clusters esperar?	✓ Sim	✗ Não	⚠ Flexível
Há muitos outliers nos dados?	✗ Não	✓ Sim	⚠ Médio
Os clusters têm formas arbitrárias?	✗ Não	✓ Sim	⚠ Médio
O dataset é grande (>10k registros)?	✓ Sim	⚠ Médio	✗ Não
Precisa de hierarquia nos clusters?	✗ Não	✗ Não	✓ Sim

Exemplo de Código Inicial:

```
import pandas as pd
```

```
import numpy as np
```

```
import matplotlib.pyplot as plt
```

```
import seaborn as sns

from sklearn.preprocessing import StandardScaler

from sklearn.decomposition import PCA

from sklearn.cluster import KMeans, DBSCAN, AgglomerativeClustering

from sklearn.metrics import silhouette_score, davies_bouldin_score

# Carregando os dados

url =
"https://raw.githubusercontent.com/datasets/credit-card-customers/main/CC_GENERAL.csv"

df = pd.read_csv(url)

# Sua análise começa aqui!

print(df.head())

print(df.info())

print(df.describe())
```

Critérios de Avaliação

Critério	Peso	O que será avaliado
Análise Exploratória	20%	Completude, qualidade das visualizações, insights
Implementação Técnica	30%	Código limpo, uso correto dos algoritmos, tratamento de dados
Justificativa	30%	Clareza na escolha, comparação entre algoritmos, métricas

Critério	Peso	O que será avaliado
Visão de Negócio	20%	Interpretação dos clusters, recomendações práticas
Bônus	10%	Criatividade, técnicas avançadas, visualizações extras

Recursos Úteis

Datasets Alternativos (se não conseguir acessar o principal):

1. **Mall Customers Dataset:** Segmentação de clientes de shopping
2. **Wholesale Customers Dataset:** Clientes de distribuidor atacadista
3. **Online Retail Dataset:** Dados de e-commerce

Leitura Recomendada:





- [Scikit-learn Clustering Guide](#)
- [Choosing the Right Clustering Algorithm](#)
- [Customer Segmentation Best Practices](#)


Prazo Sugerido

- **Análise Exploratória:** 2-3 horas
- **Implementação dos Algoritmos:** 3-4 horas
- **Análise e Comparação:** 2-3 horas
- **Relatório e Documentação:** 2 horas

Total estimado: 10-12 horas de trabalho

O que você vai aprender:

 Como tratar dados do mundo real (missing values, outliers, normalização)
  Quando usar cada algoritmo de clusterização
  Como validar e comparar resultados de clustering
  Como

traduzir resultados técnicos em insights de negócio  Como tomar decisões baseadas em dados

Suporte

Em caso de dúvidas:

- Consulte a documentação do scikit-learn
 - Revise o notebook tutorial de clusterização
 - Pergunte ao professor/monitor
 - Pesquise casos similares no Kaggle
-

Boa sorte! 

"O melhor algoritmo não é o mais complexo, mas sim aquele que resolve o problema de forma clara e eficaz."